

儿科医生统计学科普系列 | 第 04 篇

# P 值不是万能的

## 假设检验与 P 值

作者：徐铄明.杨志鹏 [PediatricXlab.com](http://PediatricXlab.com)

审校：肖莉

### 本篇核心问题

$P=0.03$  到底意味着什么？它告诉你的和你以为它告诉你的，可能完全不同。

“统计显著”和“临床有意义”之间，隔着多大的距离？

“阴性结果”是否证明“没有差异”？

## 一、两瓶退烧药的较量

小儿内科病房里，你每天都在用布洛芬（ibuprofen）和对乙酰氨基酚（acetaminophen）给发热的孩子退烧。你隐约觉得布洛芬退烧更快，但这到底是真实的差异，还是你的“错觉”？

于是你设计了一个小研究：连续纳入 100 例发热患儿，随机分为两组，分别给予布洛芬和对乙酰氨基酚，记录服药后体温降至正常的时间。结果：布洛芬组平均退烧时间比对乙酰氨基酚组快了 1.8 小时， $P=0.012$ 。

你很兴奋，准备写论文。但老板看完数据后问了一句：“ $P=0.012$ ，你觉得这说明了什么？”

你回答：“说明布洛芬比对乙酰氨基酚退烧更快啊。”

老板摇摇头：“不对。P 值告诉你的，和你以为它告诉你的，不是一回事。”

**这就是今天的主题：假设检验与 P 值。**它可能是整个统计学中被最广泛使用、也被最广泛误解的概念。

## 二、假设检验的基本逻辑：“反证法”思维

假设检验的逻辑，和法庭上的“无罪推定”很像：

- ▶ **第一步：假设“无罪”。**设立原假设（ $H_0$ ）：“两种药物的退烧时间没有差异”。这是我们的默认立场。
- ▶ **第二步：收集证据。**做实验，收集数据，计算两组的差异。

- ▶ **第三步：评估证据的“极端程度”。**如果  $H_0$  为真（真的没有差异），我们观测到的这个差异（或 1.8 小时）有多大概率会出现？这个概率就是 P 值。
- ▶ **第四步：做决定。**如果 P 值很小（小于预设的阈值，通常是 0.05），我们认为证据足以“推翻” $H_0$ ，即拒绝原假设。

让我们用图来看这个过程：




图1 P 值的含义（简化示意，仅示单侧）。蓝色曲线是  $H_0$  为真时两组差异的理论分布。红色竖线是观测到的差异 1.8 小时，红色阴影面积代表 P 值——实际检验通常采用双侧检验，需考虑两个尾部的概率之和。

### 三、P 值的正确解读：它是什么，不是什么

#### P 值是什么？

**P 值的定义：**在原假设为真的前提下，观测到当前结果（或更极端结果）的概率。

用我们的例子来说： $P=0.012$  的意思是，“如果布洛芬和对乙酰氨基酚的退烧时间真的一样，那么仅由于随机波动，我们观测到 1.8 小时（或更大）差异的概率只有 1.2%”。这个概率很小，所以我们觉得“完全没差异”这个假设不太站得住。

#### P 值不是什么？

这是最关键的部分。P 值的误解在医学文献中极为普遍：

- ▶ **P 值  $\neq$  “差异是真的”的概率。** $P=0.012$  并不意味着“有 98.8% 的概率两种药不同”。P 值的计算前提是“假设没有差异”，它没有告诉你“有差异”的概率是多少。
- ▶ **P 值  $\neq$  差异的大小。** $P=0.001$  不代表差异“很大”， $P=0.04$  不代表差异“很小”。P 值同

时受效应量和样本量影响，一个微小的差异在足够大的样本中也能产生极小的 P 值。

► **P 值 ≠ 结果的临床重要性。** 一个“统计显著”的差异可能在临床上完全无关紧要，而一个“统计不显著”的差异可能只是因为样本量不够。

#### △ 最常见的误读

“ $P < 0.05$ ，所以差异是真实的” → 错。 $P < 0.05$  只意味着在  $H_0$  为真时这个结果“不太常见”，不代表差异一定是真的。

“ $P > 0.05$ ，所以没有差异” → 错。没有拒绝  $H_0 \neq$  证明了  $H_0$ 。“没有证据证明有差异”和“证明了没有差异”是完全不同的两句话。

“P 值越小，差异越大” → 错。P 值反映的是证据与  $H_0$  的不兼容程度，不是效应的大小。

## 四、统计显著 ≠ 临床意义：一个至关重要的区分

这是假设检验中最容易被忽视的问题，我们用两个场景来说明：

### 场景 A：大样本 + 微小差异 = “统计显著”但临床无意义

每组 500 例患儿，布洛芬组服药 2 小时后体温比对乙酰氨基酚组低了  $0.22^\circ\text{C}$ ， $P < 0.001$ 。统计上极其显著，但你会因为  $0.22^\circ\text{C}$  的差异改变处方习惯吗？不会。这个差异连体温计的测量误差都可能覆盖不了。

### 场景 B：小样本 + 明显差异 = “统计不显著”但可能有临床价值

每组 25 例患儿，布洛芬组体温低了  $0.54^\circ\text{C}$ ，但  $P = 0.10$ 。“统计不显著”，但你会完全忽视半度的体温差异吗？这个“不显著”可能只是因为样本太小，检验效能不足，研究“看不见”不代表差异“不存在”。

图2 统计显著 ≠ 临床意义




图2 统计显著 ≠ 临床意义。场景 A：大样本让微小差异也“显著”；场景 B：小样本让明显差异也“不显著”。这说明 P 值同时受效应量和样本量的影响，不能单独用来判断临床价值。

临床启示

每次看到 P 值，都要同时问“差异有多大？”（效应量）和“这个差异在临床上重要吗？”  
下一篇我们会详细讲解效应量和置信区间，它们是 P 值的重要补充。

五、两类错误：假设检验的“代价”

假设检验的决定只有两种：拒绝 H0 或不拒绝 H0。无论哪种决定，都有犯错的可能。这就是统计学中著名的“两类错误”：

图3 假设检验的决策矩阵与两类错误



$\alpha$ 通常设为0.05（允许5%的假阳性率）； $\beta$ 通常期望 $\leq 0.20$ （即检验效能 $\geq 80\%$ ）

图3 假设检验的决策矩阵。I类错误 ( $\alpha$ )：误判有效；II类错误 ( $\beta$ )：漏掉真实疗效。 $\alpha$ 通常设为0.05，检验效能 ( $1-\beta$ ) 通常要求 $\geq 80\%$ 。

I类错误 ( $\alpha$ 错误)：“假阳性”

药物其实没效，但你的检验结果说“有效”。通常我们把这个错误的概率控制在 0.05（即 5%），这就是“显著性水平 $\alpha$ ”的来历。

儿科类比：就像诊断测试的“假阳性”，孩子没有病，但检查说有病。

II类错误 ( $\beta$ 错误)：“假阴性”

药物其实有效，但你的检验结果说“没检测到差异”。这通常是因为样本量太小，检验的“视力”（检验效能， $\text{power} = 1-\beta$ ）不足。我们通常要求检验效能 $\geq 80\%$ ，即 $\beta \leq 20\%$ 。

儿科类比：就像诊断测试的“假阴性”，孩子有病，但检查说没病。

### $\alpha$ 和 $\beta$ 的跷跷板

降低 $\alpha$ （更严格的显著性标准）会增加 $\beta$ （更容易漏掉真实的差异）。

反之亦然。这就像诊断测试中灵敏度和特异度的跷跷板，事实上，假设检验和诊断测试的数学框架是相通的，我们会在第12篇详细讨论。

增加样本量是同时改善 $\alpha$ 和 $\beta$ 的“免费午餐”（当然，代价是更多的时间和资源）。

## 六、常见误区

### 误区一：“ $P=0.05$ 是一条神圣的线”

$P=0.049$  和  $P=0.051$  之间没有本质区别，但很多研究者（和审稿人）把 0.05 当作“生死线”：过了就“有意义”，没过就“没意义”。实际上，0.05 这个阈值是 Ronald Fisher 时代的一个约定俗成，不是自然常数。 $P$  值应该被理解为一个连续的证据强度指标，而不是一个给出“是/否”答案的开关。

### 误区二：“结果不显著，所以两组一样”

这是临床研究中最危险的误解之一。“未能拒绝  $H_0$ ”和“证明了  $H_0$ ”是完全不同的。前者是说“证据不够”，后者是说“确定没有”。举个例子：你在房间里找钥匙，找了两分钟没找到，这不能证明钥匙不在房间里，只能说明你找的时间（样本量）可能不够。

### 误区三：P 值操纵（P-hacking）

有些研究者在  $P$  值接近 0.05 时，会尝试各种方法来“调整” $P$  值：删除离群值、换一种检验方法、增加协变量、只报告“显著”的亚组……这种做法叫 P-hacking，它会严重膨胀 I 类错误率，让完全随机的数据也能“调整”出显著的结果。预注册研究方案和报告所有分析结果，是对抗 P-hacking 的有效手段。

## 七、临床速查卡

- ◆  $P$  值 = “如果  $H_0$  为真，观测到当前（或更极端）结果的概率”。不是“差异为真”的概率。
- ◆  $P < 0.05 \neq$  差异很大； $P > 0.05 \neq$  没有差异。要同时看效应量和置信区间。
- ◆ 统计显著  $\neq$  临床意义。大样本可以让微小差异“显著”，小样本可以让明显差异“不显著”。
- ◆ I 类错误（假阳性， $\alpha$ ）和 II 类错误（假阴性， $\beta$ ）是跷跷板关系，增加样本量可以同时改善两者。
- ◆ 0.05 是约定俗成，不是自然常数。 $P$  值应被视为连续的证据强度指标。

◆ 警惕 P-hacking：如果作者报告了多个亚组分析但只展示“显著”的那个，要打问号。

## 八、延伸阅读

Wasserstein RL, Lazar NA. “**The ASA’s Statement on P-Values: Context, Process, and Purpose.**” *The American Statistician*, 2016——美国统计学会关于 P 值的官方声明，用简洁的语言阐明了 P 值的正确解读和常见误用，强烈推荐。

找一篇你最近读过的儿科 RCT 或队列研究，翻到 **Results** 部分，带着以下问题重新审视：

- ▶ 作者报告了 P 值，但是否同时报告了效应量（均值差、OR、RR 等）和置信区间？
- ▶ 有没有“统计显著但临床意义不明”的结果？作者是否在 **Discussion** 中讨论了这一点？
- ▶ 有没有“不显著”的结果被解读为“没有差异”？样本量是否足以支持这个结论？

---

### 下一篇预告

第 05 篇：效果到底有多大？——效应量与置信区间

抗生素缩短肺炎住院天数：减少 0.5 天有意义吗？用效应量和置信区间来回答。