

儿科医生统计学科普系列 | 第05篇

新的治疗方案真的更好？

从“有没有差异”到“差异有多大”

作者：徐铄明.杨志鹏 PediatricXlab.com

审校：肖莉

本篇核心问题

P 值告诉你“有没有差异”，但差异到底有多大？这才是临床决策真正需要的信息。

置信区间比 P 值多了什么信息？为什么越来越多的期刊要求必须报告 CI？

怎样一眼看懂森林图（forest plot）中的置信区间？

一、一个让你纠结的临床决策

你读到两篇关于社区获得性肺炎住院患儿的 RCT，都比较了新方案（加用某种辅助治疗）与常规方案的住院天数：

- ▶ 研究甲：新方案缩短住院 1.2 天， $P=0.003$
- ▶ 研究乙：新方案缩短住院 0.3 天， $P=0.001$

两篇都“统计显著”，P 值都很小。如果你只看 P 值，可能觉得两个方案效果差不多好。但等一下，缩短 1.2 天和缩短 0.3 天，对你的临床决策意味着完全不同的事情。1.2 天可能意味着患儿提前一天出院、家庭负担减轻、床位周转加快；0.3 天则几乎感觉不到差别。

P 值只告诉你“差异可能不是偶然的”，但不告诉你“差异有多大”。后者才是临床决策真正需要的信息，这就是效应量（effect size）的角色。

二、效应量：用数字回答“差距有多大”

效应量是对两组差异大小的量化度量。上一篇我们强调了“统计显著≠临床意义”，而效应量正是填补这个鸿沟的工具。

原始效应量：直接用临床单位表达

最直观的效应量就是两组的差值本身，用临床能理解的单位来表达：

- ▶ 均值差（Mean Difference）：治疗组（新方案）住院 7.5 天，对照组（常规方案）6.3 天，差异 1.2 天
- ▶ 风险差（Risk Difference）：治疗组（新方案）并发症率 15%，对照组（常规方案）25%，差异 10 个百分点
- ▶ NNT（Number Needed to Treat，需治疗人数）：每治疗 10 个患儿，可多让 1 个避免并发症（ $NNT = 1/|RD| = 10$ ）

这些指标的优点是直观，任何临床医生都能立刻理解治疗组（新方案）可以让患儿“少住 1.2 天”“减少并发症发生”的含义。

标准化效应量：跨研究比较的通用语言


当你需要比较不同量纲的研究（比如一篇用住院天数、另一篇用症状评分），就需要标准化效应量。最常用的是 Cohen's d：

$$\text{Cohen's } d = (\text{两组均值之差}) / (\text{合并标准差})$$

它表示同一研究内两组均值相差几个标准差，消除量纲影响，方便不同量纲研究之间的对比。Cohen 提出了一个粗略的参考标准：

Cohen's d	效应大小	临床类比
0.2	小效应	存在但不容易感知的差异
0.5	中等效应	临床上可注意到的差异
0.8	大效应	明显的、有实质影响的差异

需要注意：这只是一个经验参考，不是铁律。在不同临床场景中，“小”效应可能非常重要（如疫苗对罕见严重疾病的保护效果），而“大”效应可能临床价值有限。效应量的临床意义始终需要结合具体场景判断。



三、常见效应量指标速查

不同类型的研究设计和结局变量，使用不同的效应量指标：

结局类型	常用效应量	含义	举例
连续变量	均值差 (MD)	两组均值的差值	住院天数差 1.2 天
连续变量	Cohen's d	标准化均值差	$d = 0.67$
二分类变量	相对危险度 (RR)	治疗组事件率/对照组事件率	$RR = 0.60$ (降低 40% 风险)
二分类变量	比值比 (OR)	治疗组 odds/对照组 odds	$OR = 0.50$
二分类变量	风险差 (RD)	两组事件率的绝对差	$RD = 10\%$
二分类变量	NNT	每避免 1 例事件需治疗人数	$NNT = 10$
生存数据	风险比 (HR)	瞬时风险的比值	$HR = 0.75$ (降低 25% 风险)

RR、OR 还是 RD？

RR 和 OR 是相对指标，适合概括治疗的“相对强度”，但不直接告诉你绝对收益。

RD 和 NNT 是绝对指标，直接告诉你临床收益的大小，对决策更友好。

同一个 $RR=0.5$ ，在基线风险 50% 时意味着绝对降低 25% ($NNT=4$)，在基线风险 2% 时只降低 1% ($NNT=100$)，效果“看起来”一样，实际天壤之别。

最佳实践：相对指标和绝对指标同时报告。

四、置信区间：给效应量加上“误差线”

效应量告诉你“差异有多大”，但这只是从你的样本中估计出来的一个数字，如果再做一次研究，结果可能略有不同。置信区间 (Confidence Interval, CI) 就是量化这种不确定性的工具。

置信区间的直觉理解

假设你的研究发现新方案缩短住院 1.2 天，95% CI 为 [0.6, 1.8] 天。这意味着：如果用同样的方法反复做这个实验，有 95% 的置信区间会包含真实的效应值。通俗地说，我们有相当的信心认为真实差异在 0.6 到 1.8 天之间。

置信区间同时传递了三个信息：

- ▶ 效应量的点估计：1.2 天（区间的中心）
- ▶ 估计的精度：区间宽度 1.2 天（越窄越精确）
- ▶ 统计显著性：如果 CI 不包含 0（对于均值差）或不包含 1（对于 RR、OR），则 $P < 0.05$

置信区间如何解读？四种常见情况

下面用四个假设研究来展示 CI 的解读方法：

图2 置信区间的解读：四种常见情况




图2 置信区间的解读。研究A：显著且有临床意义；研究B：CI触及零线，证据不确定；研究C：显著但差异太小，临床意义有限；研究D：不显著，可能是样本量不足。

△ 置信区间的常见误读

“真实值有 95% 的概率落在这个区间内” → 严格来说不对。统计学频率学派的解读是：如果重复抽样，95% 的区间会包含真值。真值是固定的，不是随机的。

但在实际临床应用中，将 CI 理解为“真实效应很可能在这个范围内”是一个合理的实用近似。

关键是不要把 CI 的边界当成“硬线”，效应值落在 CI 外的可能性不是零，只是较小。

五、样本量如何影响置信区间

第04篇我们讲过，P 值同时受效应量和样本量影响。置信区间也一样，样本量越大，CI 越窄，估计越精确。




图3 同一个真实效应（约-1.2天），不同样本量下的CI宽度。 $n=20$ /组时CI从-2.6到-0.3天，跨度很大； $n=500$ /组时CI收窄到-1.4到-0.9天，估计非常精确。

这张图直观说明了一个重要原则：小样本研究的效应量估计本身不一定有偏（点估计可能很准），但精度很低（CI很宽），不确定性很大。这就是为什么小样本研究的结论需要谨慎对待，不是因为它一定错了，而是因为它“可能对也可能错”的范围太大。

六、效应量与置信区间如何改变你读文献的方式

掌握了效应量和 CI，你读文献时的思维框架会发生质的变化。以前你可能只关注 P 值的星号，

现在你可以问更深的问题：

从“有没有差异”到“差异有多大”

不要满足于“ $P < 0.05$ ，有效”。追问：效应量是多少？在临床上，这个大小的差异对患儿和家庭意味着什么？是值得改变现有的治疗方案，还是差异太小不值得折腾？

从“显著/不显著”到“精确/不精确”

CI 的宽度告诉你研究结论的可靠程度。一个显著但 CI 极宽的结果（如 $HR = 0.5$, 95% CI [0.1, 2.5]），提供的信息其实很有限，真实效应可能从“大幅获益”到“有害”都有可能。

从“单一数字”到“可能的范围”

CI 让你看到的不是一个“答案”，而是一个“范围”。如果 CI 的最差端（最不利的边界值）仍然有临床意义，那你对治疗有效的信心就很强；如果 CI 跨越了临床无关紧要的区域，即使点估计看起来不错，你也需要更大的研究来确认。

七、常见误区

误区一：只报告 P 值不报告效应量

这在儿科文献中仍然常见。一篇论文的 Results 部分全是 P 值的星号标注，却不告诉你均值差是多少、OR 是多少。没有效应量的 P 值就像只告诉你“有人比你高”但不说高多少，信息是不完整的。越来越多的期刊（如 BMJ、Lancet 系列）已经明确要求必须报告效应量和 95%CI。

误区二：用 CI 是否包含零来代替 P 值

“CI 不包含 0 就是 $P < 0.05$ ”这句话在技术上是正确的（对于 95%CI 和均值差），但如果你用 CI 的唯一目的就是判断“显著不显著”，那就浪费了 CI 提供的丰富信息。CI 的价值在于告诉你效应的范围和精度，而不仅仅是替代 P 值做一个二元判断。

误区三：混淆“无效应”和“无证据”

如果 CI 为 [-0.5, 2.0] 天，包含了 0，你可能说“没有显著差异”。但 CI 也包含了 2.0 天，这是一个有临床意义的差异。正确的解读是：“我们不能排除无效的可能，但也不能排除治疗确实有效的可能，证据不确定。”而不是简单地说“没有效果”。

八、临床速查卡

- ◆ 效应量回答“差异有多大”，P 值不回答这个问题。两者互补，不可替代。
- ◆ 原始效应量（均值差、RD、NNT）对临床决策最直观；标准化效应量（Cohen's d）用于

跨研究比较。

- ◆ Cohen's d: 0.2=小, 0.5=中, 0.8=大, 但临床意义需结合具体场景判断。
- ◆ 95% CI = 效应量的点估计 + 精度 + 显著性, 一个指标传递三重信息。
- ◆ CI 越窄越好 (精度高)。CI 宽度主要由样本量决定。
- ◆ CI 不包含 0/1 $\approx$ $P < 0.05$, 但 CI 的价值远不止于此——看范围, 看精度, 看最差端。
- ◆ 读文献必看三件套: 效应量 (有多大) + CI (多精确) + P 值 (是否偶然)。

九、活学活用

找一篇你近期关注的儿科 RCT, 对照以下清单审视 Results:

- ▶ 主要结局是否同时报告了效应量 (均值差/OR/RR)、95%CI 和 P 值? 缺了哪个?
- ▶ 效应量在临床上有意义吗? 是“统计显著但临床可忽略”还是“具有实质性影响”?
- ▶ CI 有多宽? 如果你只看 CI 的最不利端 (最靠近零的边界), 结论还成立吗?
- ▶ 如果是“阴性”结果 (CI 跨零), CI 的另一端是否包含了有临床意义的效应值? 这是真的“无效”还是“不确定”?

下一篇预告

第 06 篇: 比较越多, 错得越多——多重比较与多重检验

5 种抗癫痫药两两比较: 做 10 次 t 检验, 总有一个“显著”。多重比较问题怎么破?