

儿科医生统计学科普系列 | 第06篇

比较越多，错得越多

多重比较与多重检验

作者：徐铄明.杨志鹏 PediatricXlab.com

审校：肖莉.唐路

本篇核心问题

5种药物两两比较做10次t检验，为什么很可能“找到”一个“显著”结果？

Bonferroni校正是什么？什么时候该用，什么时候不必用？

亚组分析中的多重比较陷阱如何识别？

一、一个“惊喜”的研究结果

你和同事做了一项回顾性研究，比较5种抗癫痫药（丙戊酸（Valproic Acid, VPA）、左乙拉西坦（Levetiracetam, LEV）、奥卡西平（Oxcarbazepine, OXC）、莫三嗪（Lamotrigine, LTG）、托吡酯（Topiramate, TPM））对儿童局灶性癫痫的疗效。你把5种药物两两比较，每一对做一次独立样本t检验，一共做了 $C(5,2)=10$ 次比较。

结果令你兴奋：在10次比较中，有3对的P值小于0.05！你正准备在文章里写“VPA显著优于OXC（ $P=0.003$ ）、LEV显著优于LTG（ $P=0.032$ ）、OXC显著优于TPM（ $P=0.044$ ）”。

统计师看了一眼，说：“等一下。你做了10次检验，按纯概率，即使5种药物完全没有差异，出现至少1个 $P<0.05$ 的概率就已经超过40%了。3个‘显著’结果里，可能有2个甚至全部都是假阳性。”

这就是多重比较问题（Multiple Comparisons Problem）：当你同时做多次假设检验时，总体的假阳性率（I类错误率）会远远超过你为每次检验设定的5%。检验越多，“碰运气”撞上“显著”结果的概率越大。

二、为什么检验越多，错得越多？

第04篇我们讲过，每次假设检验都有5%的概率犯I类错误（假阳性），这是你设定的 α 水平。如果你只做1次检验，假阳性风险就是5%。但如果做多次呢？

假设你做了 k 次独立检验，每次的 $\alpha=0.05$ 。至少出现 1 次假阳性的概率（称为**家族错误率，Family-Wise Error Rate, FWER**）为：

$$\text{FWER} = 1 - (1 - \alpha)^k = 1 - 0.95^k$$

（注：以上公式假设各次检验相互独立。若检验之间存在相关性，实际 FWER 会低于此计算值。）

这个公式的结果增长很快：

检验次数 (k)	FWER	直觉理解
1	5.0%	就是你设定的 α
3	14.3%	做 3 次比较，假阳性风险翻了近 3 倍
5	22.6%	将近四分之一的概率出现假阳性
10	40.1%	5 种药两两比较的情况
20	64.2%	查 20 项血液指标的情况（第 02 篇提到过）

图1 多重检验导致假阳性率急剧膨胀




图1 多重检验导致假阳性率急剧膨胀。做 10 次检验时，即使所有药物疗效完全相同，也有 40% 的概率至少“发现”一个“显著差异”。

用生活化的类比：你抛一枚硬币，连续 20 次正面的概率极低；但如果你同时抛 100 万枚硬币，其中肯定有某些硬币出现了连续 20 次正面，不是因为这些硬币有什么特殊，而是试的次数够多。多重检验的问题本质上就是这个道理。

三、解决方案一：Bonferroni 校正，简单粗暴但有效

最经典的多重比较校正方法是 **Bonferroni 校正**：把显著性阈值除以检验次数。

如果你做了 10 次检验，原来的 $\alpha=0.05$ 就调整为 $0.05/10=0.005$ 。只有 $P<0.005$ 的结果才被认定为“显著”。这样做的效果是把整体假阳性率控制回 5%以内。




图2 Bonferroni 校正的效果。10 次比较中，未校正时 3 对“显著”（黄色+蓝色柱），但 Bonferroni 校正后（绿色阈值线 $P=0.005$ ），只有 VPA vs OXC ($P=0.003$ ，蓝色柱) 仍然显著。另外两对（黄色柱) 的“显著”很可能是假阳性。

Bonferroni 的优点

- ▶ 简单易算：新阈值 = $0.05 / \text{检验次数}$
- ▶ 保守可靠：严格控制 FWER 不超过 α
- ▶ 不需要 P 值排序或复杂计算

Bonferroni 的缺点

- ▶ 过于保守：检验次数很多时，校正后的阈值极低，真实的差异也可能被“误杀”（II 类错误增加）。例如做 100 次检验时，阈值变成 0.0005，几乎什么都“不显著”了。
- ▶ 假设所有检验独立：如果检验之间有相关性（如比较同一组患者的多个结局），Bonferroni 会过度校正。

四、更好的替代方案

Holm 校正（Holm-Bonferroni 法）

Holm 校正是 Bonferroni 的改进版。它的逻辑是：先把所有 P 值从小到大排列，然后用逐步递减的阈值来判断。最小的 P 值与 $0.05/k$ 比较，第二小的与 $0.05/(k-1)$ 比较，以此类推。一旦某个 P 值不显著，后面的全部判为不显著。

Holm 校正比 Bonferroni 更有统计效能（更不容易“误杀”），同时仍然严格控制 FWER。大多数统计学家推荐用 Holm 代替 Bonferroni。

Benjamini-Hochberg 法（FDR 控制）

当检验次数非常多（如基因组学中同时检测上万个基因），控制 FWER 就太保守了，你几乎找不到任何“显著”结果。此时可以改为控制假发现率（False Discovery Rate, FDR）：在所有被判为“显著”的结果中，允许一定比例（通常 5%）是假阳性。

FDR 比 FWER 宽松得多，更适合高通量探索性研究。但在临床试验的主要结局分析中，通常仍然要求控制 FWER。

校正方法	控制目标	保守程度	适用场景
Bonferroni	$FWER \leq \alpha$	最保守	检验次数少（ <20 ），要求严格控制
Holm	$FWER \leq \alpha$	比 Bonferroni 宽松	通用推荐，替代 Bonferroni
Benjamini-Hochberg	$FDR \leq q$	较宽松	大规模检验（基因组学、影像学）
不校正	每次检验 α	最宽松	仅 1 次检验，或明确标注为探索性

五、什么时候需要校正，什么时候不必？

这是实际操作中最让人困惑的问题。并不是所有多次检验都需要校正，关键在于检验的性质和目的。

图3 是否需要多重比较校正？决策流程




图3 是否需要多重比较校正的决策流程。预设的多重主要结局需要校正（推荐 Holm 法）；探索性分析可以不校正但必须声明；大规模检验用 FDR。

需要校正的情况

- ▶ **多个主要结局（co-primary endpoints）**：一个 RCT 同时设定了 3 个主要结局，每个都做了假设检验，必须校正，否则至少 1 个假阳性的概率是 14.3% 而不是 5%。
- ▶ **多组间两两比较**：如本文开头的 5 种药物两两比较，这是最经典的多重比较场景。通常用 Tukey HSD（配合方差分析）或 Bonferroni/Holm 校正。
- ▶ **中期分析（interim analysis）**：临床试验过程中多次“偷看”数据是否已经显著，每次偷看都消耗 α 额度，需要用 O'Brien-Fleming 或 Lan-DeMets 等方法校正。

通常不需要校正的情况

- ▶ **一个主要结局 + 多个次要结局**：只对主要结局做正式检验，次要结局报告效应量和 CI，标注为探索性即可。
- ▶ **亚组分析**：大多数亚组分析是探索性的，不做校正，但必须在文章中明确说明“亚组分析为探索性，未做多重比较校正，结果需谨慎解读”。

- ▶ **不同研究问题的独立检验：**如果在同一篇文章中回答了两个完全不同的研究问题（如同时分析疗效和安全性），这些检验之间通常不需要互相校正。

六、案例实战：识别文献中的多重比较陷阱

读文献时，以下几个信号提示可能存在未校正的多重比较问题：

- ▶ **“在亚组分析中发现……”**，如果全文主要结局不显著，但在某个亚组“发现”了显著结果，要高度警惕。这可能是对多个亚组挨个检验后碰巧撞上的假阳性。
- ▶ **结果部分有大量 P 值但没有提及校正方法**，如果一篇文章报告了 15 个比较的 P 值，而 **Methods** 部分没有说明多重比较的处理，说明要么作者没有意识到这个问题，要么有意回避。
- ▶ **“次要结局显示……”**，如果主要结局不显著，作者转而强调某个次要结局的显著性，这本质上也是一种多重比较的选择性报告。

△ 儿科文献中的高频场景

比较多种治疗方案：如不同剂量 IVIG 治疗川崎病、多种抗生素方案比较，两两比较必须校正。

基线资料表（Table 1）的多重检验：RCT 的 Table 1 通常比较两组的十几个基线变量，这些检验本身不需要校正（因为目的是描述性的，而且随机化的效果不需要用 P 值来“验证”）。

多中心研究中每个中心单独分析：如果分别在 6 个分中心检验疗效再挑“显著”的，本质上也是多重比较。

七、常见误区

误区一：“我只报告了那个显著的结果，所以不需要校正”

你做了 10 次比较，只报告了 $P < 0.05$ 的那 3 个，而对其他 7 个“不显著”的结果绝口不提，这不是解决了多重比较问题，这是 **P-hacking**。多重比较的校正取决于你做了多少次检验，而不是你选择报告了多少次。

误区二：“Bonferroni 太保守了，所以我不做任何校正”

Bonferroni 确实保守，但“不校正”不是替代方案。如果你觉得 Bonferroni 太严，可以用 Holm 校正（几乎同样简单，但效能更高），或者根据研究设计使用其他方法。“因为最严格的方法太严格，所以干脆不校正”是一种逻辑谬误。

误区三：“方差分析（ANOVA）的 F 检验显著了，所以两两比较不需要校正”

ANOVA 的 F 检验告诉你的是“至少有一对组间存在差异”，它是一个整体检验。但它没有告诉

你具体是哪一对不同。接下来做两两比较（post-hoc test）时，仍然需要多重比较校正。常用的 post-hoc 方法如 Tukey HSD、Dunnnett 检验等本身就内置了校正。

八、临床速查卡

- ◆ 做 k 次独立检验，至少 1 次假阳性的概率 = $1 - 0.95^k$ 。10 次检验 → 40% 假阳性风险。
- ◆ Bonferroni 校正：新阈值 = $0.05/k$ 。简单但保守。推荐改用 Holm 校正（效能更高）。
- ◆ 大规模检验（基因组学）→ 用 FDR（Benjamini-Hochberg）；少量检验 → 用 FWER 控制。
- ◆ 预设的多重主要结局、多组两两比较、中期分析 → 必须校正。
- ◆ 探索性亚组分析 → 不校正但必须声明为探索性，并注明多重比较风险。
- ◆ ANOVA 显著后的两两比较仍需校正（用 Tukey HSD 等 post-hoc 方法）。
- ◆ 读文献时，如果结果中有大量 P 值但 Methods 未提及校正，要打问号。

阅读练习：找一篇你近期读过的涉及多组比较的儿科研究，检查以下几点：

- ▶ 一共做了多少次假设检验？Methods 部分有没有说明多重比较的处理方法？
- ▶ 如果有多组两两比较，用的是什么 post-hoc 方法？（Tukey？Bonferroni？Dunn？）
- ▶ 有没有“主要结局不显著但亚组分析显著”的情况？作者是否注明了探索性？

下一篇预告

第 07 篇：样本量不是拍脑袋定的——样本量估算与检验效能

计划一项早产儿喂养 RCT：需要多少例才能检测到差异？从 I 类错误、II 类错误到效能分析。