儿科医生统计学科普系列 | 第 01 篇

数据会说谎吗？

描述性统计与数据可视化

作者：徐铣明.杨志鹏　PediatriXlab.com

审校：向棱棱.肖莉

本篇核心问题

为什么同一组数据，换一种统计量或换一种图，讲出来的“故事”完全不同？

作为儿科医生，如何快速识别数据描述中的“陷阱”，做出更准确的临床判断？

重医儿院大数据中

一、从一个查房故事说起

周一早交班，住院医师小张汇报了一组数据：“上个月我们新生儿科收治的 72 例新生儿，平均出生体重 3133 克，基本正常。”

主任听完，没有马上评论，而是问了一句：“中位数是多少？”

小张翻了翻数据：“中位数……3420 克。”

主任点点头：“均值比中位数低了 287 克，说明有一批低体重的孩子把均值拉下来了。你有没有看过这组数据的分布？”

小张一头雾水。

新生儿科是一个天然会产生“混合数据”的科室：它同时收治极早产儿、早产儿、足月高危儿和巨大儿。这些亚群的体重差异巨大，混在一起汇总时，一个简单的“平均值”往往掩盖了真实的群体结构。其实不只是新生儿科，任何存在明显亚组的临床数据都可能出现类似问题。

我们习惯用一个“平均值”来概括一组数据，但平均值有时候是个“好好先生”，它把极端情况都抹平了，给你一个看似正常的假象。

这就是我们今天要讨论的核心话题：描述性统计。它是统计学的起点，也是最容易被忽视的环节。很多统计分析的错误，在你还没跑任何检验之前，就已经在数据描述这一步埋下了。

二、三个“代言人”：均值、中位数与众数

描述一组数据的“中心位置”，统计学给了我们三个选项。它们各有脾气，适用于不同场合。

均值（Mean）：最民主，也最容易被“绑架”

均值就是所有数值加起来除以个数，每个观测值都有等权投票。这很民主，但问题是：一个极端值就能把结果带偏。设想新生儿里有 3 例极低出生体重儿（<1500g），尽管例数少，但对均值的拉拽效应远超其人数占比。

中位数（Median）：排在中间的那个

把所有数值从小到大排列，位于正中间的就是中位数。它对极端值完全“免疫”，不管最小值是 800 克还是 1500 克，中位数纹丝不动。这就是为什么主任查房时要追问中位数：它给出的是一个更“抗干扰”的中心位置。

众数（Mode）：谁出现得最多？

众数是一组数据中出现频率最高的值。对于连续型数据（如体重、身高），因为很少有完全相同的数值，众数通常不直接使用，但直方图的“最高峰”本质上就是众数的可视化体现。

众数真正的舞台是**分类数据**。在儿科临床中，分类变量无处不在：入院诊断、出院转归、病原学分型、用药方案……对这些变量，你没法算均值或中位数，但可以问“最常见的是哪个？”，这就是众数。

举个例子：统计新生儿科上月 72 例患儿的入院主诊断，结果可能是早产（28 例）> 新生儿肺炎（15 例）> 新生儿黄疸（12 例）> 其他（17 例）。此时“早产”就是众数，它告诉你这个新生儿科当前最主要的收治病种是什么。科室资源配置、人员排班、耗材储备，很多管理决策的起点就是这个简单的频数统计。

儿院大数据中心

临床直觉

如果均值 ≈ 中位数：数据分布大致对称，用均值没问题。

如果均值 < 中位数：有低值在拉拽（左偏），比如混入了极低体重儿。

如果均值 > 中位数：有高值在拉拽（右偏），比如住院天数中混入了长期住院的重症。

经验法则：数据有偏态或极端值时，优先报告中位数。

三、光看“平均水平”还不够——离散程度同样重要

两组新生儿的平均出生体重都是 3200 克，但一组的数据分布在 2800-3600 克之间（很集中），另一组则散布在 1200-4500 克（差异巨大）。如果你只报告均值，这两组数据看起来毫无区别，但它们背后的临床含义天壤之别。

我们需要**离散度指标**来量化数据“散开的程度”。

标准差（Standard Deviation，SD）：最常见的搭档

标准差衡量的是每个数据点偏离均值的平均距离。如果数据近似正态分布，大约 68%的数据

落在“均值±1 个 SD”范围内，95%落在“均值±2 个 SD”范围内。你在医学文献中看到的“3200±450g”就是均值±标准差的写法。

> ⚠ **常见错误**
>
> 不少文献把“均值±标准差”和“均值±标准误（Standard Error of the Mean，SEM）”混用。
>
> 标准差（SD）描述的是数据本身的离散程度；标准误（SEM）描述的是均值估计的精度。
>
> SEM = SD / √n，所以样本量越大 SEM 越小——这不代表数据更集中，只是估计更精确。
>
> 用 SEM 替代 SD 会让数据看起来比实际“整齐”得多，这是文献中常见的（有时是故意的）误导。

四分位距（(Interquartile Range，IQR）：中位数的最佳搭档

如果你选择用中位数来代表中心位置，那配套的离散度指标就是四分位距（IQR）。它等于第 75 百分位数（Q3）减去第 25 百分位数（Q1），涵盖了中间 50%的数据。医学文献中常见的写法有两种：一种是报告四分位区间，如“中位出生体重 3420 克（Q1–Q3: 3004–3599 克）”；另一种是直接报告 IQR 的差值，如“中位数 3420 克，IQR = 595 克”。前者让读者直观看到中间 50%数据的范围上下界，后者强调的是跨度本身。两种写法都可以，关键是不要把 IQR（一个差值）和 Q1–Q3 区间（两个端点）混为一谈。

> ⚠ **IQR 是差值，不是区间**
>
> IQR = Q3 − Q1，它是一个数字（如 595g），不是一个范围。
>
> “Q1–Q3: 3004–3599 克”是四分位区间，描述的是端点位置。
>
> “IQR = 595 克”是四分位距，描述的是区间跨度。
>
> 文献中经常混用这两个概念，读和写的时候都要留意。

配对原则

数据特征	中心位置指标	离散度指标	报告格式
对称分布 / 近似正态	均值 (Mean)	标准差 (SD)	3200 ± 450 g
偏态分布 / 有极端值	中位数 (Median)	IQR 或 Q1–Q3	3420 (Q1–Q3: 3004–3599) g

四、用眼睛看数据——可视化的力量

数字是抽象的，图形是直觉的。同一份数据，表格里可能看不出任何异常，但一画图就原形毕露。

直方图（Histogram）：数据分布的“全家福”

直方图把连续数据分成若干区间（bin），每个区间的柱子高度代表落在该区间的频数。它能让你一眼看到数据是对称的、偏的、还是有多个“峰”。

回到我们的新生儿体重数据。下图清楚地展示了这组数据并非一个漂亮的钟形曲线，而是在 3400-3600 克处有一个高耸的足月儿主峰，在 1200-2400 克之间散布着早产儿群体（从极早产到晚期早产），两者之间在 2600-2800 克处有一段空白（这份数据里没有体重在这个区间的新生儿）。红色虚线（均值）被低体重儿向左拉拽，偏离了绿色实线（中位数），**均值 3133 克这个数字把两个群体“平均”掉了，但直方图把真相还给了你。**

图1 新生儿出生体重分布直方图

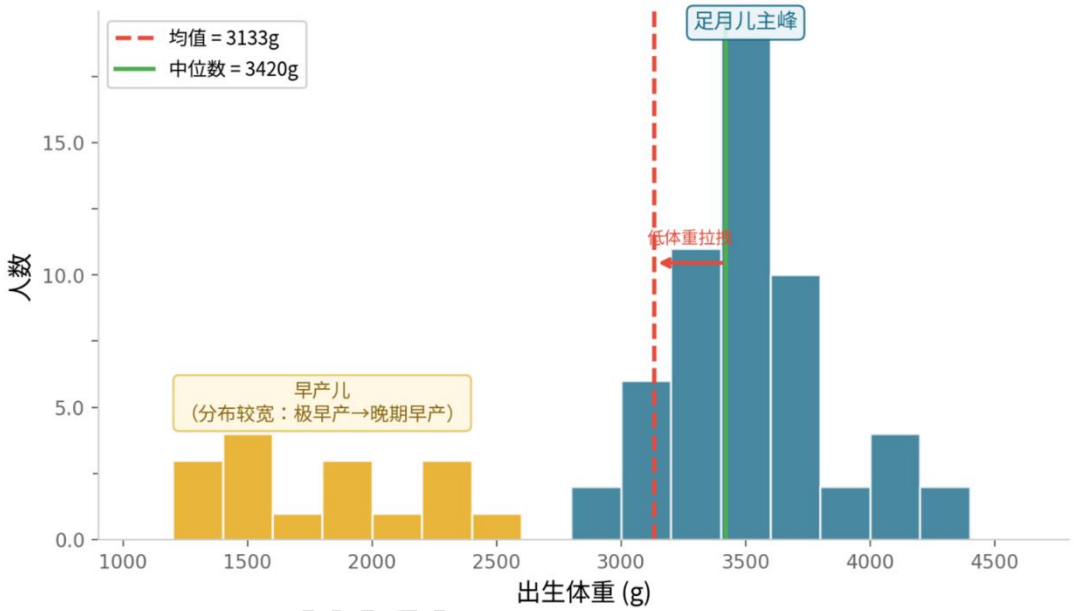

图 1 新生儿科 72 例新生儿出生体重分布直方图。黄色柱体为早产儿区间（<2500g），可见明显的双峰分布。

箱线图（Box Plot）：五个数字讲一个故事

箱线图用五个关键数值（最小值、Q1、中位数、Q3、最大值）勾勒出数据的形态。“箱子”覆盖了中间 50%的数据，中间那条线就是中位数，超出“须”（whisker）的点被标记为潜在离群值。

在临床中，箱线图最适合做分组比较。下图将同一批数据拆为早产儿组、足月儿组和全部新生儿三组并排展示。我们在“全部新生儿”这组上做了详细标注，你可以看到箱线图的五个关键位置：下须（数据范围下界）、Q1（第 25 百分位）、中位数、Q3（第 75 百分位）、上须（数据范围上界），以及超出须范围的离群值。Q1 到 Q3 之间的“箱子”覆盖了中间 50%的数据，而 IQR 就是这个箱子的“高度”（Q3 − Q1）。

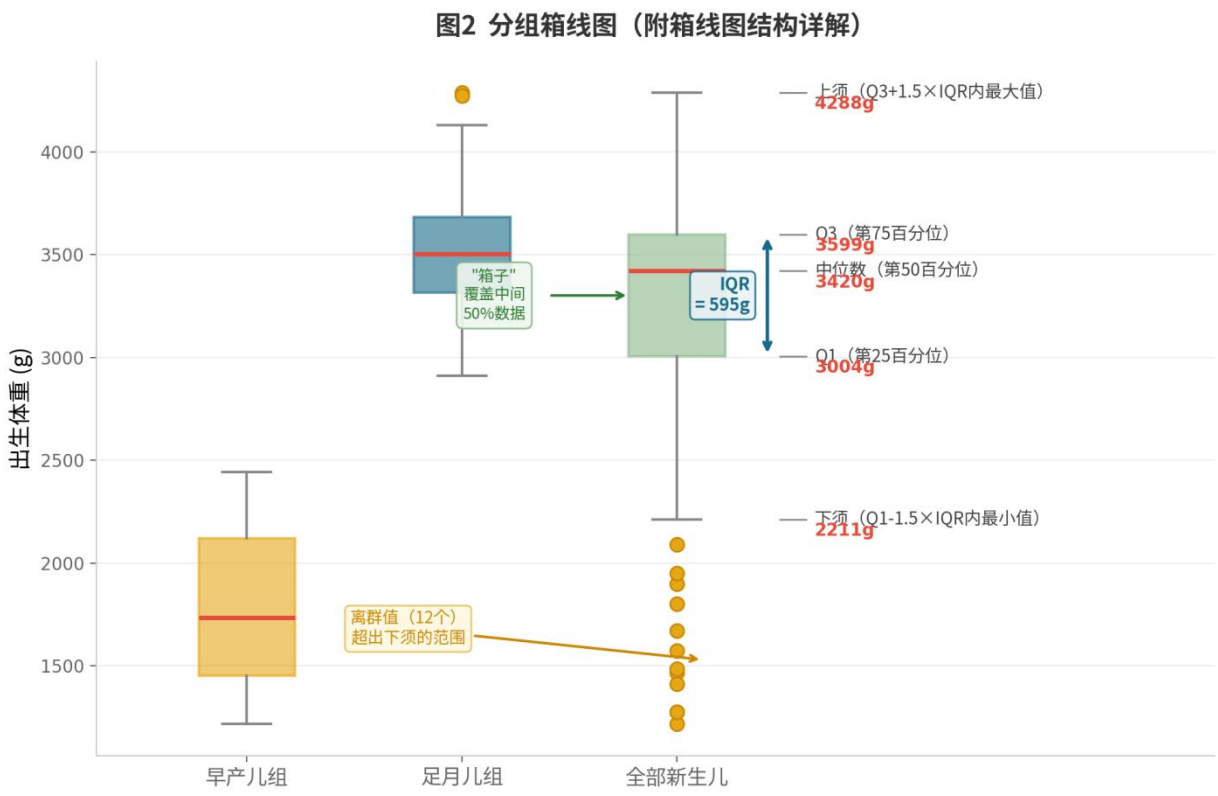

图 2 分组箱线图（附结构详解）。右侧标注了五个关键数值：须和离群值。全部新生儿组有 12 个低端离群值——正是早产儿群体。IQR = Q3 − Q1 = 595g。

散点图（Scatter Plot）：探索两个变量的关系

当你想观察两个连续变量之间的关系（例如出生胎龄与出生体重），散点图是首选。每个点代表一个患儿，横轴是胎龄，纵轴是体重。如果点的分布呈现从左下到右上的趋势，就提示正相关。

下图中有一个特别的红色菱形点：胎龄 37.5 周但体重只有 2050 克。在早产儿群体中这个体重不奇怪，但在足月儿中却是明显的离群值，提示宫内生长受限（IUGR，现也称胎儿生长受限 FGR）的可能。**这类发现往往就藏在散点图里，光看均值和标准差是发现不了的。**

重医儿院内部资料

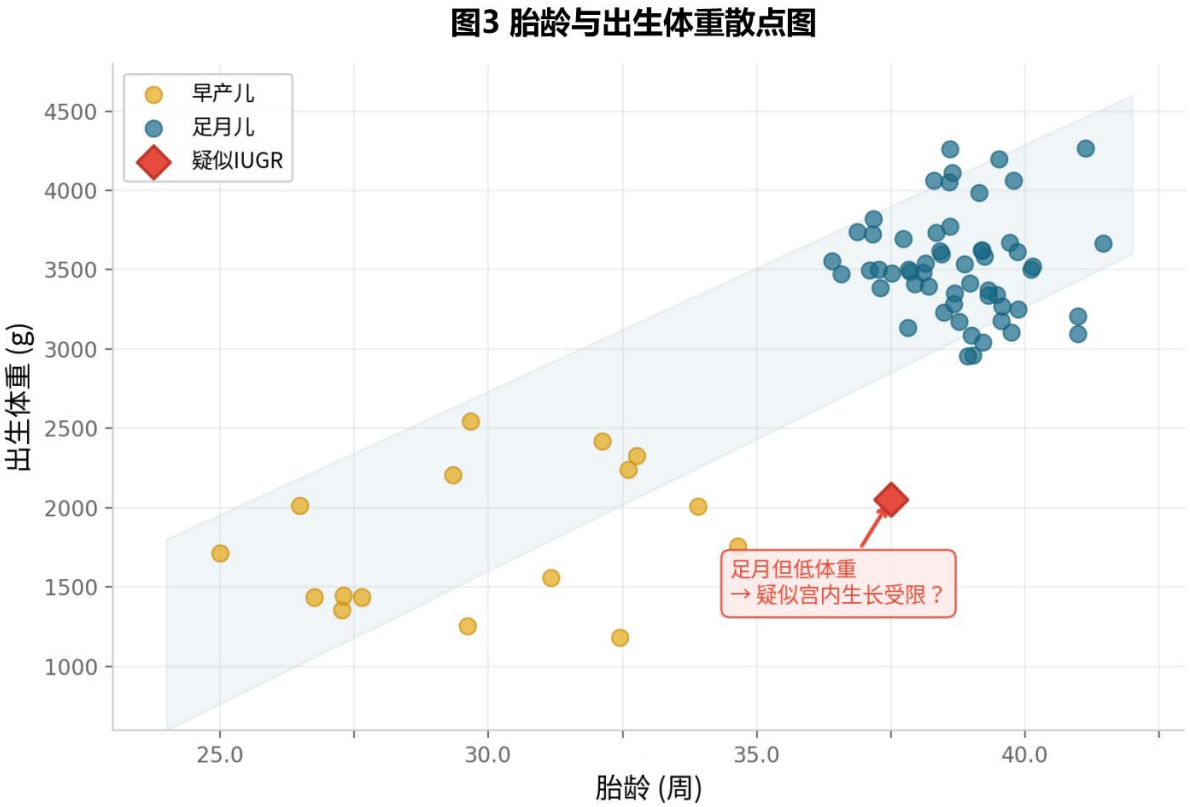

图 3 胎龄与出生体重散点图。整体呈正相关趋势，红色菱形标注了一例疑似宫内生长受限（IUGR）的足月低体重儿。

五、案例实战：新生儿科新生儿出生体重数据

让我们用上述图表中的模拟数据来完整回顾描述性统计指标。以下汇总了 72 例新生儿出生体重的关键统计量：

统计量	数值	临床解读
样本量 (n)	72	当月收治总数
均值 (Mean)	3133 g	被低体重儿拉低，不能代表“典型”水平
中位数 (Median)	3420 g	更能反映多数新生儿的体重水平
标准差 (SD)	804 g	变异很大，提示群体异质性高
最小值	1217 g	极早产儿
最大值	4288 g	巨大儿
Q1（第 25 百分位）	3004 g	四分之一的新生儿体重低于此值
Q3（第 75 百分位）	3599 g	四分之三的新生儿体重低于此值
Q1–Q3（四分位区间）	3004–3599 g	中间 50%数据的范围
IQR（四分位距）	595 g	Q3 − Q1，衡量离散程度的差值

重医儿院大数据

解读要点：

- 均值（3133g）< 中位数（3420g），差值达 287 克，提示数据存在明显的左偏，低体重方向有大量拖尾（对照图 1 可以直观验证）。
- 标准差 804g 非常大，均值±2SD 的范围是 1525-4741g，几乎覆盖了从极低出生体重到巨大儿的全范围，说明这组数据异质性极高，用单一均值来概括是不够的。
- 箱线图（图 2）中，全部新生儿组的 12 个低端离群值都为早产儿，被 IQR 的 1.5 倍规则“判定”为异常，恰好说明这些数据点不属于主体分布。这正是箱线图帮助你发现亚群的方式。
- 直方图（图 1）清楚显示了双峰分布：足月儿主峰（3400-3600g）和早产儿群体（1200-2400g，从极早产到晚期早产分布较宽），中间有完全空白的“谷”。这种双峰说明数据来自两个截然不同的亚群，此时报告整体均值几乎没有临床意义。
- 更好的做法是分组描述：分别报告足月儿和早产儿的中位数（Q1–Q3），如箱线图（图 2）所展示的那样。

六、常见误区：三个“数据陷阱”

陷阱一：对所有数据无脑报告均值±SD

住院天数是典型的右偏数据：大部分患儿住 3-7 天，但少数重症可能住 30 天以上。如果报告“平均住院天数 8.2±6.5 天”，读者会以为典型住院时长就是 8 天左右，但实际上中位数可能只有 5 天。用中位数（Q1–Q3）描述偏态数据，才是更为合理的做法。

陷阱二：用 SEM 代替 SD

前文已经提到，标准误（SEM）天然比标准差（SD）小（SEM = SD/√n），样本量越大差距越悬殊。有些作者（有意或无意地）使用 SEM，让数据的离散程度看起来很小、很“干净”。审稿和读文献时，一定要看清括号里是 SD 还是 SEM。

陷阱三：只看数字不画图

统计学里有一个经典教学案例叫 Anscombe 四重奏，虽然它不是儿科数据，但它传递的信息对所有临床研究者都至关重要：四组数据拥有几乎完全相同的均值、标准差、相关系数和回归方程，但散点图的形态天差地别，有的是线性关系，有的是曲线，有的有离群值，有的被单个杠杆点操控。

重医儿院大数据中心

图4 Anscombe四重奏：相同的统计量，不同的真相

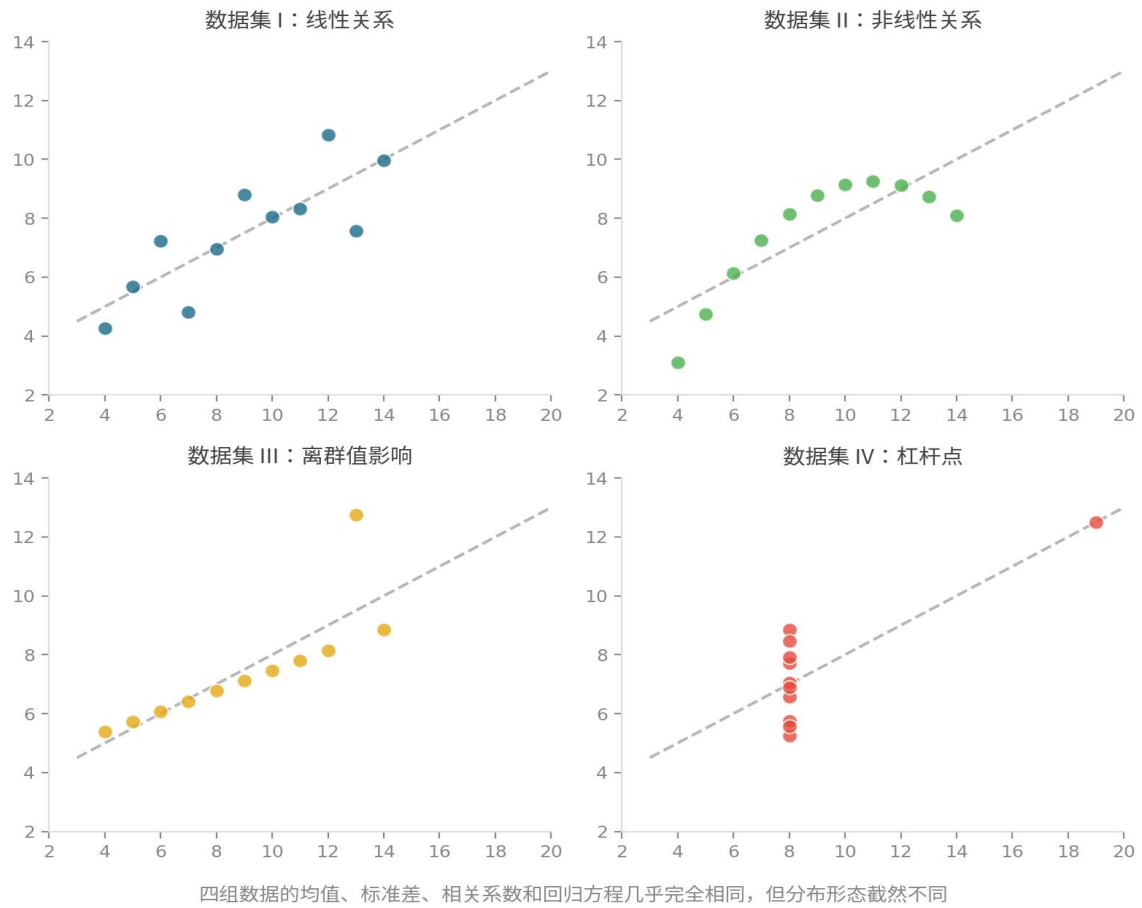

图 4 Anscombe 四重奏。四组数据的均值、标准差、相关系数和回归方程几乎一模一样，但只有画图才能看到真正的数据结构。

回到儿科场景来想：如果你只看到“CRP 均值 45mg/L，与住院天数相关系数 r=0.6”，你可能以为这是一个干净的线性关系。但画出散点图后你也许会发现，这个相关性完全是被几个 CRP 极高的脓毒症患儿“撑”起来的，去掉他们后相关性几乎消失。这就是 Anscombe 四重奏在临床中的翻版。

七、临床速查卡

- ✦ 拿到数据第一件事：画直方图（连续变量）或条形图（分类变量），看分布形态。
- ✦ 对称分布 → 报告均值 ± SD；偏态分布 → 报告中位数（Q1–Q3）或中位数（IQR）。
- ✦ 看到“均值±”时，检查括号里是 SD 还是 SEM——差别很大。
- ✦ 均值和中位数差异大 → 数据可能有偏态或极端值，需要进一步探索。
- ✦ 数据异质性高时，考虑分亚组描述，不要用一个均值“大而化之”。
- ✦ 散点图可以帮助发现离群值和变量间的关系——它们是下一步分析的线索。

✦ 永远记住 Anscombe 四重奏的教训：相同的统计量可以对应完全不同的数据结构，画图是不可替代的。

八、活学活用

找一篇你近期读过的儿科临床研究论文，翻到 Table 1（基线资料表），带着以下问题重新审视：

- 连续变量用的是均值±SD 还是中位数（Q1–Q3）？选择是否合理？
- 有没有哪个变量明显应该用中位数但作者用了均值？（提示：住院天数、费用、实验室指标常见此问题）
- 论文有没有用图（直方图、箱线图）展示关键变量的分布？如果没有，你觉得加上会不会更好？
- 分类变量报告了频数和百分比吗？最常见的类别（众数）是什么？

下一篇预告

第 02 篇："正常值"到底怎么定？——参考范围与正态分布

为什么 2 岁和 12 岁的血红蛋白"正常值"不一样？如何看懂生长曲线？

重医儿院大数据中心